

# Proyecto taller de ciencias de datos: Reducción de las falsas alarmas de arritmia en la UCI.\*

Valentina Yañez Torres

Universidad de Talca

Curicó, Chile

vyanez20@alumnos.utalca.cl

**Abstract**—Las falsas alarmas en la UCI pueden provocar una interrupción de la atención, afectando tanto al paciente como al personal clínico a través de perturbaciones acústicas, desensibilización a las advertencias y ralentización de los tiempos de respuesta, lo que lleva a una disminución de la calidad de la atención. [3]

Este proyecto tiene como objetivo el desarrollar un algoritmo para reducir la incidencia de falsas alarmas al momento de detectar arritmias potencialmente mortales en la Unidad de Cuidados Intensivos (UCI).

**Index Terms**—ECG, machine learning, arritmia, decision trees, neural networks

## I. INTRODUCCIÓN

Se utilizan datos de 1250 alarmas de arritmia en señales de unidades de monitorización de cuidados intensivos disparadas en base a diversos canales para monitoreo de ondas pulsátiles, como derivaciones ECG, presión arterial y fotoplestimografía [3]. Sin embargo, Los datos de alarmas se reparten en sólo 750 casos únicos. Fueron recopilados de cuatro hospitales en EE.UU. y Europa con tres fabricantes principales.

Los datos fueron recopilados de cuatro hospitales en EE.UU. y Europa con tres fabricantes principales [3] y se encuentran en formato '.hea' y '.mat' (Matlab).

Cada uno de los 750 registros contiene al menos una derivación de ECG y una o más formas de onda pulsátiles (fotoplestimografía y presión arterial) y han sido muestreados a 250 Hz. Los registros incluyen artefactos de marcapasos y otros ruidos. [3]

## II. OBJETIVO

### A. Reducción de Alarmas Falsas

Desarrollar algoritmos que reduzcan la cantidad de alarmas falsas en la UCI, enfocándose en arritmias que amenazan la vida como asistolia, bradicardia extrema, taquicardia extrema, taquicardia ventricular y fibrilación ventricular. Se pueden usar hasta 30 segundos de datos después de la alarma.

### B. Evaluación y Puntuación

Las entradas se deben evaluar y puntuar automáticamente en un entorno de prueba.

## III. DEFINICIONES IMPORTANTES

### A. Complejo QRS

El complejo QRS es una parte fundamental del electrocardiograma (ECG) que representa la despolarización de los ventrículos del corazón.

1) *Despolarización Ventricular:* El complejo QRS muestra la actividad eléctrica que ocurre cuando los ventrículos del corazón se despolarizan, lo que lleva a su contracción. Se presentan a continuación los componentes del complejo:

- Onda Q: La primera onda negativa del complejo.
- Onda R: La primera onda positiva.
- Onda S: La onda negativa que sigue a la onda R.

El complejo QRS es una parte fundamental del electrocardiograma (ECG) que representa la despolarización de los ventrículos del corazón. [4][5]

### B. Ondas pulsátiles

Son variaciones periódicas en la presión de los vasos sanguíneos, causadas por el bombeo del corazón. Estas ondas se pueden medir a través de diferentes métodos, como la fotoplestimografía (PPG) o la presión arterial.

1) *Tipos de canales de onda pulsátil presentes en los datos:*

- ABP (Arterial Blood Pressure): Mide la presión arterial en tiempo real, fundamental para el monitoreo cardiovascular.
- PLETH (Plethysmogram): Representa la variación del volumen sanguíneo en un lecho vascular, útil para evaluar la perfusión y la saturación de oxígeno.
- MCL (Modified Chest Lead): Derivación ECG que proporciona una visualización clara del ritmo cardíaco y ayuda en la detección de arritmias.
- II (Lead II): Una derivación estándar que mide la actividad eléctrica del corazón desde el brazo derecho a la pierna izquierda.
- V (Precordial Lead): Derivaciones colocadas en el tórax para obtener información detallada sobre la actividad eléctrica del corazón.
- aVR, aVL, aVF: Derivaciones unipolares que ofrecen información sobre el eje eléctrico del corazón y son útiles en la evaluación de isquemia.
- RESP (Respiratory Rate): Mide la frecuencia respiratoria del paciente, crucial para evaluar su estado respiratorio.

[1][5]

### C. Tipos de arritmia consideradas

El problema solo se enfoca en algunas arritmias potencialmente mortales, a saber: asistolia, bradicardia extrema,

taquicardia extrema, taquicardia ventricular y aleteo/fibrilación ventricular.

- Asistolia: Sin QRS durante al menos 4 segundos
- Bradicardia extrema: Frecuencia cardíaca inferior a 60 lpm durante 5 latidos consecutivos
- Taquicardia extrema: Frecuencia cardíaca superior a 140 lpm durante 17 latidos consecutivos
- Taquicardia ventricular: 5 o más latidos ventriculares con frecuencia cardíaca superior a 100 lpm
- Aleteo ventricular/Fibrilación: Fibrilatoria, aleteo o forma de onda oscilatoria durante al menos 4 segundos

[2]

#### D. Preparación de entorno

Se ha instalado el lenguaje Python junto con sus respectivas librerías para el manejo, filtrado y limpieza de datos, la ejecución de modelos de machine learning y la evaluación de la eficiencia de dichos modelos.

- NumPy: Proporciona soporte para arreglos y matrices multidimensionales, así como funciones matemáticas de alto nivel para operar sobre estos datos.
- Pandas: Facilita la manipulación y análisis de datos estructurados, permitiendo operaciones como filtrado, limpieza y transformación de conjuntos de datos.
- SciPy: Ofrece herramientas para el procesamiento de señales y funciones científicas, incluyendo métodos para la carga y guardado de archivos de datos.
- Matplotlib: Utilizada para la visualización de datos a través de gráficos estáticos, animados e interactivos.
- WFDB: Permite trabajar con bases de datos fisiológicas y realizar análisis sobre señales biomédicas.
- BioSPPy: Proporciona funciones específicas para el procesamiento y visualización de señales biomédicas, como ECG y PPG.
- Scikit-learn: Una biblioteca integral para machine learning que incluye herramientas para la creación, evaluación y ajuste de modelos predictivos.
- Imbalanced-learn (imblearn): Ofrece técnicas para el tratamiento de conjuntos de datos desbalanceados, facilitando el uso de métodos como SMOTE para la sobre-muestreo.
- TensorFlow/Keras: Proporciona una plataforma robusta para construir y entrenar modelos de aprendizaje profundo, incluyendo redes neuronales convolucionales.

1) *Visualización de los datos:* Se implementaron varias funciones para la obtención y lectura de datos desde archivos en diferentes formatos. La función `get_name_files` permite listar todos los archivos de un directorio que tienen una extensión específica, facilitando la identificación de los archivos relevantes para el análisis. La función `read_file_hear` se encarga de leer archivos de encabezado (.hea) utilizando la biblioteca WFDB, extrayendo información sobre las señales. Por otro lado, `read_file_mat` carga archivos .mat que contienen las señales biomédicas, mientras que `read_file_flat` y `read_file_zigzag` están

diseñadas para extraer áreas específicas del contenido de estos archivos, verificando si las variables correspondientes ('flatareas' y 'zigzagareas') están presentes en los datos. En caso de no encontrarlas, estas funciones retornan un arreglo vacío, asegurando así una gestión adecuada de los datos.

#### E. Análisis exploratorio preliminar

Se realizó un análisis exploratorio de datos utilizando el registro `a1031`, que contiene tres señales distintas (II, V, PLETH) muestreadas a 250 Hz, con una longitud total de 82,500 muestras. Estas señales están registradas en un formato de 16 bits y con resoluciones de 16 bits en el convertidor analógico-digital (ADC). Durante el análisis, se identificó un evento clínico significativo: la detección de una asistolia que resultó ser una falsa alarma. Esta información es crucial, ya que los comentarios asociados al registro proporcionan contexto sobre eventos clínicos relevantes.

#### F. Descripción de los Datos del Registro ECG

- Nombre del Registro: `a1031`
- Número de Señales: 3
- Frecuencia de Muestreo: 250 Hz
- Duración de la Señal: 82,500 muestras
- Comentarios: ['Asystole', 'False alarm']
- Nombres de las Señales: ['II', 'V', 'PLETH']
- Nombre de Archivos: ['a1031.mat', 'a1031.mat', 'a1031.mat']
- Formato de Datos: ['16', '16', '16']
- Ganancia del ADC: [7247.0, 10520.0, 12530.0]
- Unidades: ['mV', 'mV', 'mV']
- Resolución del ADC: [16, 16, 16]
- Valores Iniciales: [-171, 9127, 6042]
- Checksum: [-27403, -301, -17391]

### IV. LIMPIEZA Y SELECCIÓN DE DATOS

Gracias a las funciones de visualización, se pudieron observar características importantes de las señales. En primer lugar, se notó que las señales no tenían una longitud estándar, muchas presentaban ruido y no se podía identificar claramente el complejo QRS. Además, varios canales mostraban líneas planas y en zigzag, lo que dificultaba aún más la detección de características relevantes. Ante estas observaciones, se estableció el siguiente plan de acción:

- Detección de líneas planas y zigzag.
- Desarrollo de un filtro Butterworth de paso bajo, con un corte (cutoff) de 1 Hz y orden 2.
- Clasificación de datos válidos para entrenamiento y testing.

A continuación, se detallan las funciones relevantes a esto dentro del código:

`mark_flat_lines`: Esta función marca líneas planas en la señal donde la diferencia entre valores consecutivos es menor que un umbral.

- Parámetros:
  - `signal`: La señal a analizar (ECG o PPG).
  - `fs`: Frecuencia de muestreo en Hz.

- `min_duration`: Duración mínima en segundos para que se considere una línea plana.
- `flat_value`: El valor que se utilizará para marcar las líneas planas en la señal.
- `threshold`: Umbral de diferencia entre muestras consecutivas para considerar una línea plana.

- Retorna:

- `marked_signal`: La señal con las líneas planas marcadas.
- `flat_areas`: Lista de tuplas (inicio, fin) que indican las áreas planas detectadas.

`mark_zigzag_lines`: Esta función identifica segmentos en zigzag dentro de una señal.

- Parámetros:

- `signal` (numpy array): La señal a analizar.
- `fs` (int): Frecuencia de muestreo en Hz (por defecto es 250 Hz).
- `min_duration` (float): Duración mínima en segundos de un zigzag (por defecto es 0.2 segundos).

- Retorna: `zigzag_areas` (list): Lista de tuplas (inicio, fin) que indican los segmentos en zigzag.

Tanto `min_duration` como `threshold` fueron ajustados para detectar correctamente señales sin actividad significativa o con nula actividad.

1) *Selección de datos válidos*: Debido a la naturaleza de los datos, existen casos donde ninguno de los canales disponibles es adecuado para la extracción de características. Esto puede ocurrir si no se detectan correctamente los latidos cardíacos y los complejos QRS, o si se presentan líneas planas o patrones erráticos que corrompen el canal. Por lo tanto, se procede a identificar y eliminar estos datos del conjunto de entrenamiento. Posteriormente, se revisa cuántas señales quedan calificadas para el entrenamiento de los modelos.

2) *Limpieza de los datos válidos*: Se utiliza la librería Biosppy para la normalización de datos y extracción de características, complementada con un filtro de paso de banda. Tras esta limpieza, se extraen las características relevantes de cada caso y se almacenan los canales ECG y PPG en un vector. Aunque se extraen muchas características relevantes en una señal ECG, no todas son utilizadas en el modelo final.

#### A. Extracción de características

Las señales válidas se convierten en un DataFrame utilizando la librería Pandas. A continuación, se realiza un filtrado para seleccionar las características más importantes para la detección de anomalías cardíacas:

- Frecuencia Cardíaca Máxima del ECG (`max_heart_rate_ecg`): Indica episodios de taquicardia y ayuda a evaluar la capacidad aeróbica.
- Frecuencia Cardíaca Mínima del ECG (`min_heart_rate_ecg`): Detecta bradicardia, señalando posibles bloqueos cardíacos.
- Raíz Cuadrada de la Media de las Diferencias Cuadráticas Sucesivas (`rmssd`): Mide la variabilidad de la frecuencia cardíaca; una alta variabilidad indica buena salud.

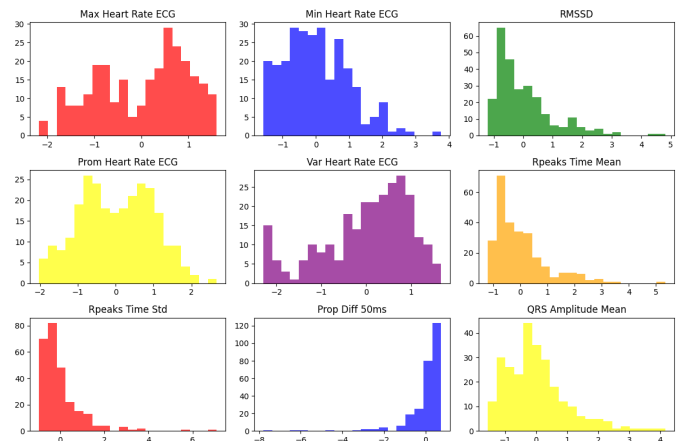


Fig. 1. Distribución de características seleccionadas

- Tipo de Anomalía (`anomaly_type`): Clasifica irregularidades en el ECG, como asistolia.
- Promedio de la Frecuencia Cardíaca del ECG (`prom_heart_rate_ecg`): Ofrece una visión general del ritmo cardíaco normal.
- Varianza de la Frecuencia Cardíaca del ECG (`var_heart_rate_ecg`): Refleja la estabilidad del ritmo cardíaco.
- Promedio del Tiempo entre Picos R (`rpeaks_time_mean`): Evalúa la consistencia en los intervalos entre latidos.
- Desviación Estándar del Tiempo entre Picos R (`rpeaks_time_std`): Indica la regularidad del ritmo cardíaco.
- Proporción de Diferencias de Intervalo Mayor a 50 ms (`prop_diff_50ms`): Mide la variabilidad en los intervalos entre picos R.
- Promedio de la Amplitud del QRS (`qrs_amplitude_mean`): Relacionada con la fuerza de contracción ventricular.
- Simetría del Complejo QRS (`qrs_symmetry`): Proporciona información sobre la eficiencia de despolarización ventricular.

Este proceso asegura que solo las señales con características adecuadas sean utilizadas para entrenar modelos efectivos en la detección y clasificación de anomalías cardíacas.

#### B. Análisis y normalización de características

Para garantizar la efectividad de la posterior normalización de los datos, se realizaron gráficos que analizan la distribución de las características seleccionadas. Este análisis es crucial, ya que la forma en que se distribuyen los datos influye en la técnica de normalización a aplicar. Se presentan los histogramas correspondientes a cada característica en Fig. 1.

1) *Normalización de características*: Se utilizó la normalización z-score para las características que mostraron una distribución aproximada a la normal. Este método transforma los datos para que tengan una media de 0 y una desviación estándar de 1, lo que es especialmente útil para datos con

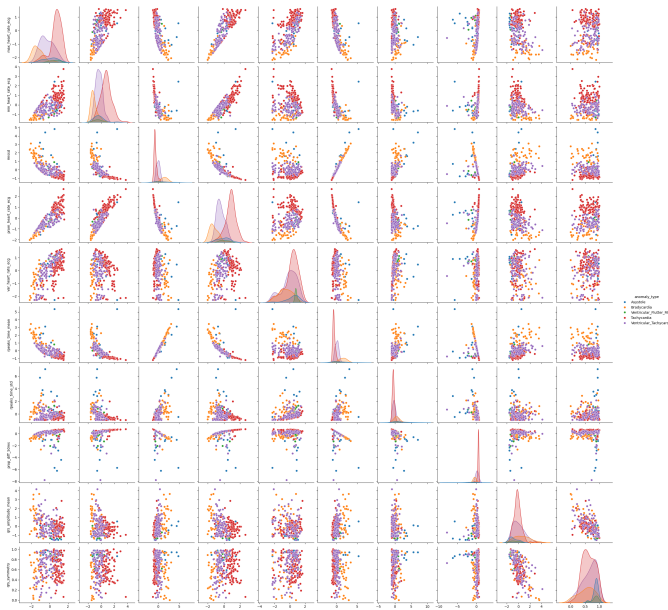


Fig. 2. Gráfico correlativo entre características y etiquetas

distribución normal. Las características normalizadas mediante z-score son:

- Frecuencia Cardíaca Máxima del ECG (max\_heart\_rate\_ecg)
- Frecuencia Cardíaca Mínima del ECG (min\_heart\_rate\_ecg)
- Raíz Cuadrada de la Media de las Diferencias Cuadráticas Sucesivas (rmssd)
- Promedio del Tiempo entre Picos R (rpeaks\_time\_mean)
- Desviación Estándar del Tiempo entre Picos R (rpeaks\_time\_std)
- Promedio de la Frecuencia Cardíaca del ECG (prom\_heart\_rate\_ecg)
- Promedio de la Amplitud del QRS (qrs\_amplitude\_mean)
- Proporción de Diferencias de Intervalo Mayor a 50 ms (prop\_diff\_50ms)

Para aquellas características que presentaron distribuciones sesgadas o no normales, se aplicó una transformación logarítmica. En particular, esto fue necesario para la Varianza de la Frecuencia Cardíaca del ECG (var\_heart\_rate\_ecg) y se realizó después de restar el valor mínimo para evitar problemas con valores cero. Posteriormente, se aplicó también la normalización z-score a esta característica transformada.

Para la característica Proporción de Diferencias de Intervalo Mayor a 50 ms (prop\_diff\_50ms), se eliminaron los valores cero antes de aplicar la transformación logarítmica.

Para las características que no presentaron una distribución normal y donde se prefirió mantener el rango original sin transformaciones logarítmicas, se utilizó un escalador Min-Max. Este método ajusta los valores a un rango específico, generalmente entre 0 y 1.

2) *Correlación entre características y etiquetas:* Fig. 2 detalla la relación y distribución entre los atributos escogidos,




Fig. 3. Pérdida final de red neuronal

así como la distribución de las etiquetas en el plano. Este gráfico proporciona una visión clara de las tendencias presentes en los datos. Al analizar el gráfico, se puede observar una tendencia de división lineal en algunas comparativas de características. Esto sugiere el uso de árboles de decisión como modelo de clasificación, ya que estos algoritmos son particularmente efectivos para identificar límites de decisión lineales y no lineales en los datos. Además, se probaron redes neuronales como otra alternativa para la clasificación de anomalías cardíacas. Las redes neuronales, ya que han demostrado ser eficaces en la identificación de patrones complejos dentro de los datos, gracias a su capacidad para aprender representaciones jerárquicas.

### C. Desarrollo de algoritmos de aprendizaje automático

En el proceso de clasificación de anomalías cardíacas, se probaron varios modelos, incluyendo redes neuronales, árboles de decisión y Random Forest. Esta diversidad en el enfoque permite evaluar cuál modelo se adapta mejor a las características del conjunto de datos y proporciona el mejor rendimiento en términos de precisión y capacidad de generalización.

1) *Redes Neuronales:* Se implementó una red neuronal con regularización L2 para reducir la pérdida y mejorar la generalización del modelo.

La regularización L2 con un valor de 0.5 se aplicó en la capa oculta para penalizar los pesos grandes y así reducir el sobreajuste, como se ve en Fig. 3.

Los resultados obtenidos del modelo se resumen en la Tabla 1

2) *Árbol de decisión:* Debido a que el rendimiento de redes neuronales no fué el esperado, se utilizó un árbol de decisión como modelo alternativo, cuyos resultados de muestran en Tabla 2.

Clase	Precisión	Recall	F1-Score	Soporte
Asystole	0.68	0.57	0.62	23
Bradycardia	0.67	0.80	0.73	15
Tachycardia	0.77	0.93	0.84	29
V. Flutter/Fibrillation	0.65	0.89	0.76	19
V. Tachycardia	0.71	0.41	0.52	29
<b>Exactitud</b>	<b>0.70</b>			<b>115</b>
<b>Macro Avg</b>	<b>0.70</b>	<b>0.72</b>	<b>0.69</b>	<b>115</b>
<b>Weighted Avg</b>	<b>0.70</b>	<b>0.70</b>	<b>0.69</b>	<b>115</b>

TABLE I

MÉTRICAS DE EVALUACIÓN DEL MODELO DE REDES NEURONALES

Clase	Precisión	Recall	F1-Score	Soporte
Asystole	1.00	0.71	0.83	21
Bradycardia	0.84	0.89	0.86	18
Tachycardia	0.82	0.82	0.82	22
V. Flutter/Fibrillation	0.91	1.00	0.95	31
V. Tachycardia	0.76	0.83	0.79	23
Micro Avg	0.86	0.86	0.86	115
Macro Avg	0.87	0.85	0.85	115
Weighted Avg	0.87	0.86	0.86	115
Samples Avg	0.86	0.86	0.86	115

TABLE II

MÉTRICAS DE EVALUACIÓN DEL MODELO DE ÁRBOL DE DECISIÓN

3) *Random Forest*: Además de las redes neuronales y los árboles de decisión, se implementó un modelo de Random Forest.

Clase	Precisión	Recall	F1-Score	Soporte
Asystole	0.86	0.78	0.82	23
Bradycardia	0.88	0.93	0.90	15
Tachycardia	0.96	0.93	0.95	29
V. Flutter/Fibrillation	0.86	1.00	0.93	19
V. Tachycardia	0.78	0.48	0.60	29
<b>Micro Avg</b>	<b>0.88</b>	<b>0.80</b>	<b>0.84</b>	<b>115</b>
<b>Macro Avg</b>	<b>0.87</b>	<b>0.83</b>	<b>0.84</b>	<b>115</b>
<b>Weighted Avg</b>	<b>0.87</b>	<b>0.80</b>	<b>0.82</b>	<b>115</b>
<b>Samples Avg</b>	<b>0.80</b>	<b>0.80</b>	<b>0.80</b>	<b>115</b>

TABLE III

MÉTRICAS DE EVALUACIÓN DEL MODELO DE RANDOM FOREST

#### D. Resultados generales de precisión

El modelo de árbol de decisión fue el que obtuvo la mayor precisión con un 86.09%, seguido por Random Forest con un 80%, y finalmente, la red neuronal alcanzó un 76.63%.

#### V. DISCUSIÓN

Los resultados obtenidos en la clasificación de anomalías cardíacas mediante los modelos de machine learning, aunque no alcanzaron las expectativas iniciales de precisión, son aceptables y ofrecen un punto de partida para futuras mejoras. La diferencia en precisión entre modelos puede atribuirse a varios factores. Los árboles de decisión son conocidos por su capacidad para manejar datos categóricos y su simplicidad en la interpretación. Random Forest, al ser un conjunto de árboles de decisión, debería mejorar la robustez y reduce el riesgo de sobreajuste, aunque en este caso no fue muy efectivo. Por otro lado, las redes neuronales, que son buenas con representaciones complejas, requieren más datos para entrenarse adecuadamente y pueden verse afectadas por problemas de sobreajuste si no se gestionan correctamente incluido

el desbalance de datos. Esto puede explicar su rendimiento relativamente más bajo en comparación con los modelos basados en árboles. Además, un factor que contribuyó a la falta de precisión es el desbalance en el conjunto de datos. A pesar de que se aplicó la técnica SMOTE (Synthetic Minority Over-sampling Technique) para abordar este problema, algunas clases, como Ventricular Flutter/Fibrillation, contaban con un número muy limitado de muestras (solo cinco datos), lo que afecta negativamente la capacidad del modelo para aprender patrones representativos. También es importante considerar que los modelos utilizados se basaron en características extraídas y transformadas. Un enfoque alternativo podría haber sido analizar las señales en bruto o enfocarse en la forma del complejo QRS utilizando redes neuronales recurrentes (LSTM), que son más adecuadas para capturar las dependencias temporales en los datos.

#### VI. CONCLUSIONES

En conclusión, los modelos implementados para la clasificación de anomalías cardíacas mostraron resultados aceptables, destacando el rendimiento del árbol de decisión con una precisión del 86.09%. Aunque estos resultados son alentadores, también subrayan la necesidad de mejorar el tratamiento del desbalance en los datos y explorar enfoques alternativos más sofisticados. Es evidente que se requieren más esfuerzos para abordar las clases con escasos datos y optimizar el rendimiento general. Además, considerar métodos alternativos como el análisis directo de las señales ECG o el uso de LSTM podría abrir nuevas oportunidades para mejorar la precisión y efectividad del diagnóstico. La combinación de diferentes enfoques y técnicas avanzadas será fundamental para avanzar en la clasificación precisa de anomalías cardíacas y contribuir a diagnósticos más confiables en entornos clínicos.

#### REFERENCES

- [1] Revista Cubana de Informática Médica. (2018). *Detección de puntos clínicos de interés de la onda de pulso arterial*. Recuperado de [http://scielo.sld.cu/scielo.php?pid=S1684-18592018000100005script=sci\\_arttext](http://scielo.sld.cu/scielo.php?pid=S1684-18592018000100005script=sci_arttext).
- [2] CINC. (2015). *Proceedings of the Computing in Cardiology Conference*. Recuperado de <https://www.cinc.org/archives/2015/pdf/0733.pdf>.
- [3] PhysioNet. (2015). *2015 Challenge Data*. Recuperado de <https://physionet.org/content/challenge-2015/1.0.0/>.
- [4] Healio. (n.d.). *ECG Interpretation Tutorial: QRS Complex*. Recuperado de <https://www.healio.com/cardiology/learn-the-heart/ecg-review/ecg-interpretation-tutorial/qrs-complex>.
- [5] SIAC. (n.d.). *EKG y Arritmias*. Recuperado de <https://www.siacardio.com/wp-content/uploads/2015/01/Libro-EKG-y-Arritmias-WU.pdf>.
- [6] SHAIIO. (n.d.). *Bradycardia*. Recuperado de <https://www.shaiio.org/bradycardia>.
- [7] Margolis, T., Thaqi, A., & Esati, B. (n.d.). *Report on MSc Project*. Recuperado de <https://www.ifi.uzh.ch/dam/jcr:88645ffa-e895-4f05-b0e0-9260cd097cda/ReportMScProjektMargolisThaqiEsati.pdf>.
- [8] KLU. (n.d.). *Accuracy, Precision, Recall, F1*. Recuperado de <https://klu.ai/glossary/accuracy-precision-recall-f1>.